

EBOOK · APPLIED AI LEAD · 2026

Skills, Cowork e Tokens

Como usar o Claude de forma mais inteligente, econômica e eficiente no dia a dia.

5

CAPÍTULOS

3

MODELOS

100%

PRÁTICO

NL

Nilton Lima

Applied AI Lead · [linkedin.com/in/niltonlimafilho](https://www.linkedin.com/in/niltonlimafilho)

Sobre o autor



Nilton Lima

APPLIED AI LEAD

Tenho mais de 14 anos de liderança em Customer Experience. Nesse caminho, migrei para a fronteira da IA aplicada. Deixei de ser um líder operacional para me tornar um construtor de soluções inteligentes.

Hoje lidero a frente de Applied AI Solutions dentro de uma diretoria de Customer Support. Meu trabalho é transformar desafios operacionais complexos em arquiteturas escaláveis com IA que realmente funcionam no dia a dia das equipes.

Uso Claude todo dia pra automatizar tarefas, estruturar conhecimento em skills e economizar tempo real. Este ebook reúne o que aprendi sobre como fazer isso sem desperdiçar token nem esforço.

 linkedin.com/in/niltonlimafilho

O QUE VOCÊ VAI APRENDER

Índice de conteúdo

 Introdução Por que este manual existe	01 Tokens O que gasta, o que não gasta, na prática	02 Modelos Haiku, Sonnet e Opus. Preço, poder e escolha
03 Skills Instruções que o Claude aprende uma vez	04 CLAUDE.md O contexto permanente que substitui reexplicações	05 Cowork vs Chat Quando usar cada modo de trabalho



Introdução

Por que este manual existe

O PONTO DE VIRADA

Eu sabia usar o Claude. Não sabia economizar nele.

Passei meses escrevendo o mesmo briefing em toda conversa nova, sem perceber que isso tinha custo real.

Cada sessão começava do zero. Eu reexplicava quem era, o que fazia, como preferia receber resposta. O Claude entregava exatamente o que eu pedia, mas a conta de token subia junto com a reexplicação.

A virada aconteceu quando entendi como o token é contado de verdade, antes de tentar economizar nele. Só depois disso fez sentido usar Skill e CLAUDE.md como ferramenta de economia, não só de organização.

O QUE MUDA COM ISSO

Entender token é a base. Skill guarda o que se repete, sem gastar mais por isso. CLAUDE.md guarda quem você é, e se paga em token já na segunda sessão. As três coisas juntas mudam o custo real de usar Claude todo dia.

Como ler este ebook

- ▶ **Capítulos 1 e 2** explicam o problema: como token é contado, e como escolher modelo certo.
- ▶ **Capítulos 3 e 4** mostram a solução: Skill pra tarefa repetida, CLAUDE.md pra contexto fixo, os dois pensados pra economizar o token que você acabou de entender.
- ▶ **Capítulo 5** fecha com quando usar Cowork em vez de chat.

01

Tokens

O que gasta, o que não gasta, na prática

CAPÍTULO 1

Tudo que o Claude faz gasta token

Um token é um pedaço de texto: uma sílaba, uma palavra inteira ou uma pontuação. Na prática, 1 token equivale a 0,75 palavras em inglês, e 0,6 palavras em português. Morfologia mais complexa gera mais tokens, e é por isso que o mesmo texto em português custa mais que em inglês.



Input tokens

Sua mensagem, histórico, arquivos anexados, CLAUDE.md e Skills. Cobrados a taxa menor.



Output tokens

Texto de resposta, código, perguntas de validação. Cobrados 5x mais que input, em qualquer modelo.



Tokens de ferramentas

Cada uso de ferramenta, como ler arquivo, Drive ou código, gera entrada e saída próprias.



Contexto acumulado

O histórico inteiro é reenviado a cada turno. Dez rodadas custam bem mais que dez vezes a primeira.

Na prática: uma resposta de 2.000 tokens custa o mesmo que enviar 10.000 tokens de input. Por isso perguntas de confirmação e notificações de progresso pesam mais do que parecem.

Onde isso mais aparece

- ▶ **Sessões de Cowork**, que geram várias mensagens internas de progresso antes da resposta final.
- ▶ **Conversas longas**, onde o contexto acumulado infla o custo de cada nova rodada.
- ▶ **Prompts vagos**, que geram idas e vindas de esclarecimento antes de chegar no resultado certo.

Cada mensagem do Claude conta

Perguntas de confirmação e notificações de progresso consomem output tokens. Contam contra o seu uso, mesmo sem ser a resposta final.

Numa sessão de Cowork, uma tarefa de organização de arquivos pode gerar de 30 a 50 mensagens internas. Muitas são pequenas notificações que, somadas, chegam a mil tokens ou mais, antes mesmo de você ver o resultado.

Exemplo real de custo

Custo de uma tarefa simples

AI

CLAUDE · ~40 TOK

Vou ler os 5 arquivos agora.

AI

CLAUDE · ~160 TOK

2 arquivos lidos, com resumo de conteúdo.

AI

CLAUDE · ~400 TOK

Resposta final com o resumo completo.

VOCÊ

EU

"Analisa os 5 PDFs e me diz o que cada um contém."

TOTAL DA RODADA

~700 tokens de output no total. ~30,0% foram mensagens intermediárias de progresso, não a resposta final que você realmente queria.

Multiplique isso por uma sessão de 30 a 50 mensagens internas, e fica claro por que o Cowork consome mais rápido que uma conversa simples de chat.

02

Haiku, Sonnet e Opus

Três modelos, três situações, uma regra simples

CAPÍTULO 2



Escolha o modelo certo

A família Claude tem três modelos. Cada um é otimizado para um tipo de tarefa. Escolher errado não quebra nada, mas desperdiça tempo ou capacidade.

RÁPIDO

Haiku

Velocidade máxima para tarefas simples



Velocidade 
Raciocínio 

Use quando: classificações, traduções, formatações, resumos curtos, testes rápidos de prompt.

EQUILIBRADO

Sonnet

O ponto ideal para o dia a dia



Velocidade 
Raciocínio 

Use quando: documentos, código, análises, automações. Cobre ~80,0% do dia a dia.

PODEROSO

Opus

Máxima inteligência + Code Execution

Velocidade 
Raciocínio 

Use quando: problemas complexos, arquitetura de soluções, bugs difíceis, análises estratégicas.

REGRA DE OURO

Começa com **Sonnet**. Se a resposta for superficial, sobe para **Opus**. Se a tarefa for simples e repetitiva, desce para **Haiku**.

Preço por 1 milhão de tokens

HAIKU 4.5

Input \$1,00 · Output \$5,00 · Contexto 200K · Custo relativo 1x (base)

SONNET 4.6

Input \$3,00 · Output \$15,00 · Contexto 1M · Custo relativo 3x Haiku

OPUS 4.8

Input \$5,00 · Output \$25,00 · Contexto 1M · Custo relativo 5x Haiku / 1,67x Sonnet

CAPÍTULO 3

Ensine o Claude uma vez, use sempre

Toda tarefa que se repete, você recomeça do zero. Reexplica o passo a passo, o formato esperado, o critério que usa pra decidir. Toda vez, a mesma coisa.

O problema: sem um lugar fixo pra guardar isso, cada conversa nova começa sem nenhuma memória de como você faz aquela tarefa. Reexplicar vira mensagem extra, e mensagem extra é output, o tipo de token mais caro, como vimos no capítulo 1.

Uma Skill resolve isso. É um arquivo de instruções que você cria uma vez. O Claude passa a usar automaticamente em toda conversa relevante, sem você repetir nada.



O que é, na prática

Uma pasta com um arquivo SKILL.md dentro. O cabeçalho diz ao Claude quando usar a skill, o corpo traz as instruções completas.



Como o Claude lê

Lê o cabeçalho de todas as Skills instaladas no início de cada conversa. O corpo só carrega quando a tarefa bate com a descrição.

Por que economiza tokens: lembra do capítulo 1, output custando 5x mais que input? Com 20 Skills instaladas, o Claude carrega só os cabeçalhos, cerca de 3 linhas cada. Ter muitas Skills não aumenta o gasto. Elimina justamente as mensagens de reexplicação que pesam mais no output, e o Claude pula direto pra execução.

Como criar uma Skill

⚡ JEITO RÁPIDO

- ▶ Abra o Cowork no app desktop
- ▶ Digite `/skill-creator`
- ▶ Responda as perguntas sobre a tarefa
- ▶ Instale via Settings → Capabilities → Skills

✂ JEITO MANUAL

- ▶ Crie uma pasta com o nome da skill
- ▶ Dentro, crie o arquivo SKILL.md
- ▶ Adicione o cabeçalho YAML e as instruções
- ▶ Faça upload em Settings → Skills

```
--- name: relatorio-semanal description: Gera relatório semanal com métricas e próximos passos. Usar quando pedirem relatório ou update semanal. --- ## Instruções 1. Headline com a métrica principal 2. Progresso por etapa (%) 3. Riscos, com severidade 4. Próximos passos, com prazo Tom formal. Máximo 2 páginas.
```

Prompt pra criar sua primeira Skill

Não escreva o SKILL.md sozinho. Peça pro Claude te ajudar a construir, mostrando exemplos reais do que você já faz manualmente.

Quero criar uma skill no Claude pra automatizar [a tarefa que você refaz manualmente]. Antes de montar qualquer coisa, me faça as perguntas necessárias pra entender o processo direito. Não escreva a skill de uma vez, valide comigo primeiro.

Estou anexando 2 a 3 exemplos de como eu faço isso hoje. Use esses exemplos pra identificar: quais dados eu preciso antes de começar, quais critérios eu uso pra decidir o resultado, como estrutura a entrega final, e qual é o meu tom real de escrita.

Liste o que você identificou e pergunte o que ficou faltando. Só depois que eu confirmar critérios, estrutura e tom, monte a skill completa.

● Tarefa ● Contexto ● Formato ● Validação

CAPÍTULO 4

O sistema operacional do Claude

Toda conversa nova começa do zero. Quem você é, como trabalha, que tom prefere, tudo isso você reexplica de novo, mesmo já tendo explicado ontem.

O problema: cada reexplicação vira uma resposta mais cara em token, porque o Claude só sabe o que está na conversa atual. Sem contexto fixo, você paga esse preço em toda sessão nova.

O CLAUDE.md resolve isso. É um arquivo de contexto permanente que o Claude lê no início de cada sessão de trabalho, substituindo a explicação que você daria de qualquer forma.

Onde fica o CLAUDE.md

1

Cowork

Dentro da pasta de trabalho que você aponta para o Claude. Lido ao iniciar a sessão.

2

Claude Code

Em `~/.claude/CLAUDE.md` (global) ou `/seu-projeto/CLAUDE.md` (por projeto).

3

Projetos no Claude.ai

No campo Project Instructions, dentro do projeto criado.

O que colocar ali dentro

ALTO IMPACTO

- ▶ Quem você é e o contexto do trabalho
- ▶ Preferências de formato e tom
- ▶ Restrições e regras de comportamento

NÃO PERTENCE ALI

- ▶ Instruções de tarefas específicas viram Skills
- ▶ Conteúdo longo que raramente muda vai em arquivo separado, referenciado pelo CLAUDE.md

ECONOMIZA TOKENS?

Sim, e de forma direta. No capítulo 1 vimos que reexplicar contexto vira output, e output custa 5x mais que input. Um CLAUDE.md bem escrito custa entre **200 e 500 tokens**. Uma sessão longa sem ele gasta de **1.000 a 3.000 tokens** só em mensagens de reexplicação. A conta se paga já na segunda ou terceira sessão.

Prompt pra criar seu CLAUDE.md

Descreva o que muda a qualidade da resposta, não a tarefa em si. Isso é o que separa um CLAUDE.md útil de um genérico.

Quero montar um CLAUDE.md pra parar de reexplicar contexto toda conversa. Me pergunte o que for preciso antes de escrever.

Sobre mim: [cargo, área, o que você faz no dia a dia]. Prefiro respostas [direto, formal, técnico], no formato [bullet, prosa, tabela]. Essas são as regras que eu sempre aplico: [liste 2 a 3 regras fixas de estilo ou comportamento].

Monte um CLAUDE.md de no máximo 500 tokens, só com o que realmente muda a qualidade da resposta. Deixe de fora qualquer instrução de tarefa específica, isso vira Skill separada.

● Tarefa ● Contexto ● Regras fixas ● Validação

CAPÍTULO 5

A diferença que muda o resultado

Chat responde, analisa e gera texto e código para você usar. Cowork executa tarefas, cria arquivos e entrega resultados prontos.

CHAT

- ▶ Você executa as ações
- ▶ Só arquivos enviados manualmente
- ▶ Web, mobile, desktop
- ▶ Consumo linear, uma mensagem por vez

COWORK

- ▶ O Claude executa as ações
- ▶ Lê e escreve em pastas do computador ou Drive
- ▶ Apenas no app desktop (Windows/macOS)
- ▶ Consumo multiplicado, vários passos por tarefa

O que o Cowork consegue fazer



Acessar arquivos sem você enviar

Aposte uma pasta com Word, Excel, PDF, imagens ou código.



Criar e salvar arquivos no seu PC

Gera Word, Excel ou PDF direto na pasta indicada.



Executar tarefas multi-etapa

Planeja, executa em sequência e só chama quando precisa decidir.



Usar conectores e MCPs

Gmail, Drive, Calendar e Slack durante a tarefa, sem copiar e colar.

A REGRA MAIS SIMPLES

Se o trabalho vive em arquivos e ferramentas, use o **Cowork**. Se vive na conversa, use o **chat**.

O que lembrar de tudo isso

Depois de organizar tudo isso, essas são as lições que ficaram.

- ✓ **Skills**
Instruções que o Claude aprende uma vez. Use `/skill-creator` no Cwork.
- ✓ **CLAUDE.md**
Contexto permanente. Quem você é, tom, regras. Economiza reexplicação.
- ✓ **Toda mensagem gasta token**
Confirmações e notificações contam. Concisão no CLAUDE.md reduz isso.
- ✓ **Haiku, Sonnet, Opus**
Simples, dia a dia e complexo. Opus custa 5x mais que Haiku.
- ✓ **Regra final**
Cwork é para o que vive em arquivos. Chat é para o que vive na conversa.

Se esse ebook foi útil, compartilha com alguém que ainda reexplica tudo toda conversa. Cada pessoa que aprende a estruturar isso trabalha melhor com menos esforço.

Por onde começar

SE VOCÊ TRABALHA SOZINHO

- ▶ Escreva um CLAUDE.md simples hoje, com quem você é e como prefere receber resposta
- ▶ Transforme a tarefa mais repetitiva da semana numa Skill

SE VOCÊ LIDERA UM TIME

- ▶ Padronize um CLAUDE.md base pra todo o time usar
- ▶ Mapeie qual tarefa recorrente do time vale virar Skill primeiro

APPLIED AI LEAD · 2026

Skills, Cowork e Tokens

Por Nilton Lima, Applied AI Lead

 linkedin.com/in/niltonlimafilho